1 Giới thiệu

Phân tích cảm xúc (Sentiment Analysis) là một bài toán thuộc lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP), nhằm xác định thái độ hoặc cảm xúc được thể hiện trong văn bản.

Trong bài tập này, mục tiêu là phân loại các đánh giá phim IMDB thành hai nhóm: tích cực (Positive) và tiêu cực (Negative).

Bài tập tập trung xây dựng mô hình Long Short-Term Memory (LSTM), đồng thời so sánh hiệu quả của mô hình này với các phương pháp học máy truyền thống và mạng neural cơ bản.

Các mô hình được sử dụng bao gồm:

- Logistic Regression;
- Linear Support Vector Machine (SVM);
- Multi-Layer Perceptron (MLP);
- Long Short-Term Memory (LSTM).

Mục tiêu của việc so sánh là đánh giá hiệu quả phân loại của từng mô hình trên cùng một tập dữ liệu kiểm tra, từ đó phân tích ưu điểm, hạn chế và các hướng cải thiện.

2 Dữ liệu

Bộ dữ liệu IMDB được sử dụng để thực hiện bài toán phân loại cảm xúc của các đánh giá phim bằng tiếng Anh. Dữ liệu bao gồm hai nhãn: Positive và Negative.

Mỗi mẫu dữ liệu chứa nội dung đánh giá và nhãn cảm xúc tương ứng. Văn bản được tiền xử lý và chuyển đổi thành dạng biểu diễn phù hợp với từng mô hình.

2.1 Tiền xử lý dữ liệu

Các bước tiền xử lý chính bao gồm:

- Loại bỏ các mẫu dữ liệu không hợp lệ hoặc bị thiếu;
- Chuẩn hóa nhãn cảm xúc thành dạng số;
- Chia dữ liệu thành tập huấn luyện và tập kiểm tra;
- Biểu diễn văn bản bằng TF-IDF đối với các mô hình học máy và MLP;
- Mã hóa văn bản thành chuỗi token đối với LSTM.

Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80:20. Phương pháp chia phân tầng (stratified split) được sử dụng để duy trì tỷ lệ các lớp giữa hai tập.

Tất cả các mô hình được đánh giá trên cùng tập kiểm tra nhằm bảo đảm tính nhất quán khi so sánh.

3 Phương pháp thực hiện

3.1 Logistic Regression

Logistic Regression là một phương pháp phân loại nhị phân, ước lượng xác suất một đánh giá thuộc lớp Positive hoặc Negative.

Văn bản được biểu diễn bằng TF-IDF (Term Frequency–Inverse Document Frequency). Phương pháp này đánh giá mức độ quan trọng của từ trong một văn bản so với toàn bộ tập dữ liệu.

Xác suất dự đoán được biểu diễn dưới dạng:

$$P(y = 1 \mid x) = \sigma(w^T x + b),$$

trong đó σ là hàm sigmoid, x là vector đặc trưng, w là vector trọng số và b là hệ số chệch.

3.2 Support Vector Machine

Linear SVM tìm một siêu phẳng phân chia hai lớp dữ liệu sao cho biên phân loại được tối ưu.

Mô hình sử dụng đặc trưng TF-IDF tương tự Logistic Regression. Linear SVM thường phù hợp với dữ liệu văn bản có số lượng đặc trưng lớn và là một baseline phổ biến cho bài toán phân loại văn bản.

3.3 Multi-Layer Perceptron

Multi-Layer Perceptron (MLP) là mạng neural truyền thẳng gồm lớp đầu vào, các lớp ẩn và lớp đầu ra.

Trong bài tập này, MLP sử dụng vector TF-IDF để học mối quan hệ giữa đặc trưng văn bản và nhãn cảm xúc.

Khác với LSTM, MLP không trực tiếp duy trì trạng thái ẩn theo thứ tự các từ trong chuỗi. Do đó, mô hình chủ yếu học từ biểu diễn đặc trưng đầu vào thay vì cơ chế xử lý tuần tự.

3.4 Long Short-Term Memory

LSTM là một biến thể của mạng neural hồi quy (Recurrent Neural Network – RNN), được thiết kế để học các phụ thuộc trong chuỗi dữ liệu.

Mô hình LSTM được triển khai bằng PyTorch, bao gồm các thành phần:

- **Embedding:** chuyển token thành vector biểu diễn;
- **LSTM layer:** xử lý chuỗi từ và cập nhật trạng thái ẩn;
- **Dropout:** hỗ trợ hạn chế hiện tượng quá khớp;
- **Fully connected layer:** tạo đầu ra phục vụ phân loại.

Review được chuyển thành chuỗi token, giới hạn độ dài và padding để các mẫu trong một batch có cùng kích thước.

Đầu ra của mô hình được chuyển thành xác suất bằng hàm sigmoid:

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Với ngưỡng phân loại 0.5, mô hình dự đoán Positive nếu $p \geq 0.5$ và Negative nếu $p < 0.5$.

4 Phương pháp đánh giá

Hiệu quả của các mô hình được đánh giá thông qua Accuracy, Precision, Recall và F1-score.

4.1 Accuracy

Accuracy là tỷ lệ dự đoán chính xác trên tổng số mẫu:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

4.2 Precision

Precision thể hiện tỷ lệ dự đoán Positive chính xác trong số tất cả các mẫu được dự đoán là Positive:

$$\text{Precision} = \frac{TP}{TP + FP}.$$

4.3 Recall

Recall thể hiện tỷ lệ mẫu Positive được nhận diện chính xác:

$$\text{Recall} = \frac{TP}{TP + FN}.$$

4.4 F1-score

F1-score là trung bình điều hòa của Precision và Recall:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

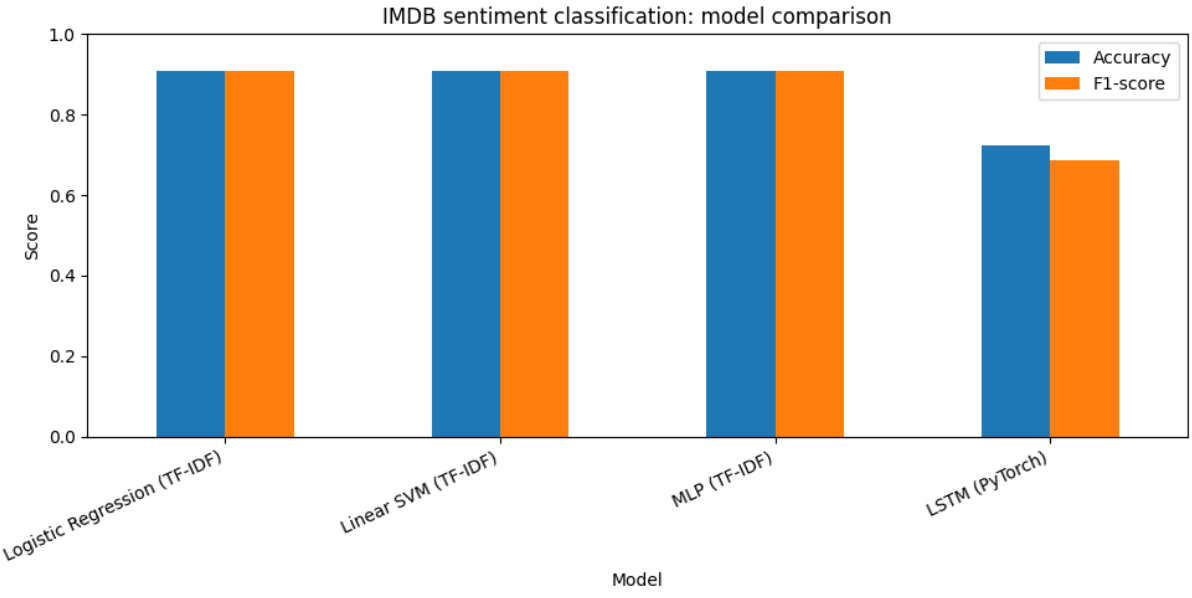
Trong đó:

- TP: số mẫu Positive được dự đoán đúng;
- TN: số mẫu Negative được dự đoán đúng;
- FP: số mẫu Negative bị dự đoán nhầm thành Positive;
- FN: số mẫu Positive bị dự đoán nhầm thành Negative.

5 Kết quả thực nghiệm

5.1 So sánh hiệu quả các mô hình

Hình 1 minh họa kết quả so sánh Accuracy và F1-score của bốn mô hình.



Hình 1: So sánh Accuracy và F1-score của các mô hình

Bảng 1 trình bày các kết quả xấp xỉ được quan sát từ biểu đồ. Giá trị chính xác cần được lấy từ file `comparison.csv` do notebook tạo ra.

Bảng 1: So sánh hiệu quả các mô hình

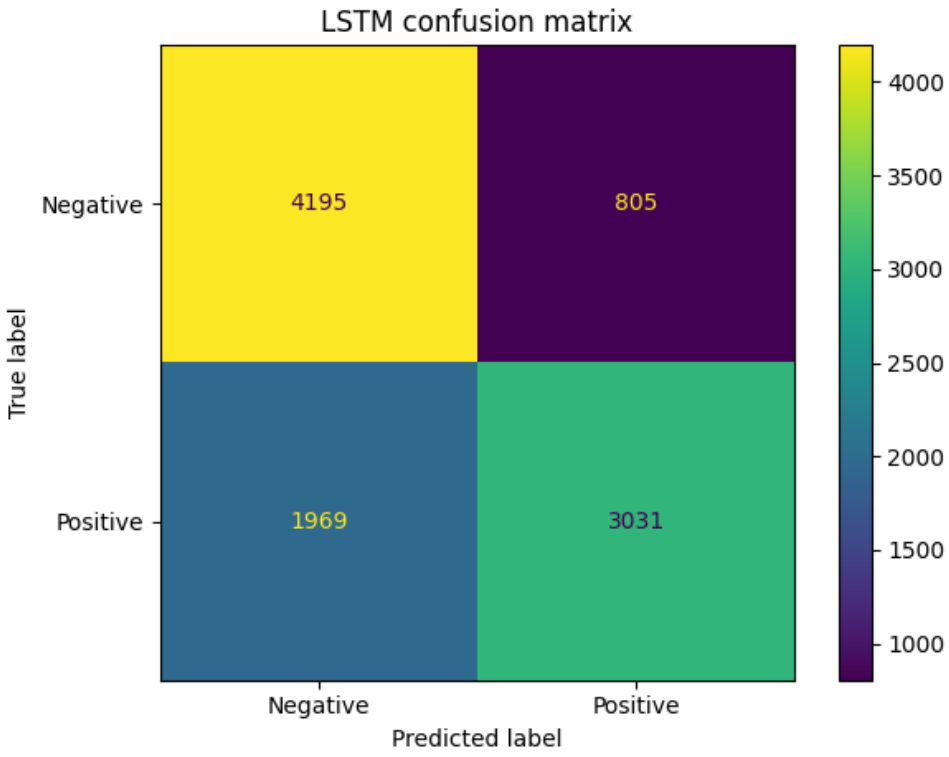
Mô hình	**Accuracy**	**F1-score**
Logistic Regression (TF-IDF)	≈ 0.91	≈ 0.91
Linear SVM (TF-IDF)	≈ 0.91	≈ 0.91
MLP (TF-IDF)	≈ 0.91	≈ 0.91
LSTM (PyTorch)	0.7226	0.6869

Kết quả cho thấy Logistic Regression, Linear SVM và MLP đạt hiệu quả cao hơn LSTM trong lần thực nghiệm này. Ba mô hình đầu có Accuracy xấp xỉ 91%, trong khi LSTM đạt Accuracy khoảng 72.26%.

Điều này cho thấy kiến trúc phức tạp hơn không đồng nghĩa với hiệu quả phân loại cao hơn trong mọi trường hợp. Kết quả còn phụ thuộc vào cách biểu diễn văn bản, cấu hình mô hình và quá trình huấn luyện.

5.2 Confusion Matrix của LSTM

Hình 2 biểu diễn confusion matrix của mô hình LSTM trên tập kiểm tra gồm 10,000 mẫu.



Hình 2: Confusion matrix của mô hình LSTM

Các giá trị trong confusion matrix được trình bày trong Bảng 2.

Bảng 2: Confusion matrix của LSTM

Nhãn thực tế	**Dự đoán Negative**	**Dự đoán Positive**
Negative	4195	805
Positive	1969	3031

Từ confusion matrix, có thể xác định:

- 4,195 mẫu Negative được phân loại chính xác;
- 805 mẫu Negative bị phân loại nhầm thành Positive;
- 3,031 mẫu Positive được phân loại chính xác;
- 1,969 mẫu Positive bị phân loại nhầm thành Negative.

Tổng số dự đoán đúng là:

$$TP + TN = 3031 + 4195 = 7226.$$

Do đó, Accuracy được tính như sau:

$$\text{Accuracy} = \frac{7226}{10000} = 0.7226 = 72.26\%.$$

Với lớp Positive là lớp được xem xét, Precision được tính bằng:

$$\text{Precision} = \frac{3031}{3031 + 805} \approx 0.7901.$$

Recall của lớp Positive là:

$$\text{Recall} = \frac{3031}{3031 + 1969} \approx 0.6062.$$

F1-score tương ứng là:

$$F_1 = 2 \cdot \frac{0.7901 \cdot 0.6062}{0.7901 + 0.6062} \approx 0.6869.$$

Các kết quả cho thấy mô hình có Precision tương đối tốt đối với lớp Positive, nhưng Recall chỉ đạt khoảng 60.62%. Điều này cho thấy một tỷ lệ đáng kể các đánh giá tích cực chưa được nhận diện chính xác.

Số mẫu Positive bị phân loại sai là 1,969, lớn hơn số mẫu Negative bị phân loại sai là 805. Vì vậy, trong lần thực nghiệm này, mô hình nhận diện lớp Negative tốt hơn lớp Positive.

6 Thảo luận

6.1 So sánh các phương pháp

Logistic Regression: Mô hình có cấu trúc đơn giản, thời gian huấn luyện tương đối thấp và hoạt động hiệu quả khi các đặc trưng TF-IDF thể hiện rõ thông tin cảm xúc.

Linear SVM: Mô hình phù hợp với dữ liệu văn bản nhiều chiều và có khả năng xây dựng ranh giới phân loại hiệu quả. Tuy nhiên, đầu ra của Linear SVM không trực tiếp là xác suất nếu chưa thực hiện hiệu chỉnh.

MLP: MLP có khả năng học các quan hệ phi tuyến giữa những đặc trưng đầu vào. Tuy nhiên, mô hình không trực tiếp duy trì trạng thái theo thứ tự từ.

LSTM: LSTM có khả năng xử lý chuỗi theo thứ tự và học các phụ thuộc trong ngữ cảnh. Đổi lại, mô hình có thể cần nhiều tài nguyên tính toán hơn và hiệu quả phụ thuộc đáng kể vào cấu hình huấn luyện.

6.2 Các nguyên nhân có thể ảnh hưởng đến kết quả LSTM

Có một số giả thuyết có thể giải thích hiệu quả thấp hơn của LSTM trong lần thực nghiệm này.

1. **Biểu diễn TF-IDF có hiệu quả đối với review.** Các từ và cụm từ mang tính cảm xúc có thể cung cấp thông tin mạnh cho các mô hình Logistic Regression và SVM.

2. **Cấu hình LSTM chưa tối ưu.** Vocabulary size, embedding dimension, hidden dimension, learning rate và số epoch đều có thể ảnh hưởng đến kết quả.

3. **Giới hạn độ dài chuỗi.** Việc cắt các review dài có thể làm mất một số từ hoặc câu quan trọng.

4. **Quá trình huấn luyện.** Mô hình có thể chưa hội tụ đầy đủ nếu số epoch chưa đủ hoặc siêu tham số chưa phù hợp.

Các nguyên nhân trên là những giả thuyết cần được kiểm tra thêm. Chỉ dựa trên Accuracy và confusion matrix hiện tại thì chưa thể xác định nguyên nhân chính xác của sự khác biệt.

7 Hướng cải thiện

Để nâng cao hiệu quả của LSTM, có thể thực hiện các thử nghiệm sau:

1. Tăng số epoch và theo dõi loss, accuracy trên tập validation.

2. Điều chỉnh learning rate, embedding dimension và hidden dimension.
3. Thử nghiệm các giá trị vocabulary size và độ dài chuỗi khác nhau.
4. Sử dụng validation set để lựa chọn cấu hình tốt nhất.
5. Thử nghiệm GRU hoặc BiLSTM để so sánh các kiến trúc tuần tự.
6. Phân tích các review bị dự đoán sai nhằm xác định các trường hợp khó phân loại.

Các thử nghiệm cần giữ nguyên tập kiểm tra để bảo đảm tính nhất quán trong quá trình so sánh. Tập test không nên được sử dụng để điều chỉnh siêu tham số.

8 Kết luận

Bài tập đã triển khai và so sánh bốn phương pháp phân loại cảm xúc trên bộ dữ liệu IMDB, bao gồm Logistic Regression, Linear SVM, MLP và LSTM.

Trong kết quả thực nghiệm hiện tại, ba mô hình sử dụng TF-IDF đạt Accuracy xấp xỉ 91%, trong khi LSTM đạt Accuracy 72.26%. Confusion matrix cho thấy LSTM nhận diện lớp Negative tốt hơn lớp Positive và còn bỏ sót một số lượng đáng kể các đánh giá tích cực.

Kết quả nhấn mạnh rằng việc lựa chọn mô hình cần dựa trên hiệu quả thực nghiệm, đặc điểm dữ liệu và chi phí tính toán. Mặc dù LSTM có khả năng xử lý thông tin tuần tự, mô hình cần được tối ưu và đánh giá thêm trước khi có thể phát huy lợi thế so với các phương pháp truyền thống.

Thông qua bài tập, có thể hiểu rõ hơn sự khác biệt giữa phương pháp biểu diễn văn bản bằng TF-IDF và phương pháp học biểu diễn chuỗi bằng embedding kết hợp LSTM, đồng thời nắm được quy trình đánh giá và so sánh các mô hình học máy trong bài toán xử lý ngôn ngữ tự nhiên.

Tài liệu

[1] A. L. Maas et al., *Learning Word Vectors for Sentiment Analysis*, Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies, 2011.

[2] S. Hochreiter and J. Schmidhuber, *Long Short-Term Memory*, Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.

[3] F. Pedregosa et al., *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[4] PyTorch, *PyTorch Documentation*. Available at: https://pytorch.org/docs/